GREENCRAFT PRO

应用效果说明

园林电动工具跨境智能客服系统

参赛赛道　第三届江苏省高校"丝路电商"创新挑战赛 · 赛道一 OPC 智能体创新应用

参赛团队　丝路智算队

验证对象　线上产物 `index.html` 中的真实引擎（未使用 mock）

报告版本　v2.1（品类动态快捷提问版 · 2026-11-03）

意图准确率 100%　品类准确率 100%　一次解决率 98.6%　决策时延 0.05–0.10 ms　零外部请求

> 📌 **本报告的数据口径**
>
> 本报告中的每一个数字，都由项目仓库中随代码提交的脚本对**线上产物本身**执行得出，可由任何第三方在本地复现。报告中**不含任何估算、推测或"行业普遍认为"式的数字。**凡本系统当前无法实测的指标（如客户满意度 CSAT、真实退货率），报告中明确标注为"需企业试点采集，当前无实测值"。

一、验证方法与可复现性

1.1 为什么这份报告是可信的

智能体类参赛作品最常见的问题是"演示很好看，但说不清它到底准不准"。本项目采取的做法是：**把测试直接架在生产产物上。**

线上产物 `index.html` 是一个零依赖的单文件应用，测试代码不重写、不复制任何业务逻辑，而是**在运行时把其中的 `<script>` 块抽取出来**，在 Node 的最小 DOM 桩中执行，直接调用线上真实的 `detectIntent` / `detectProduct` / `findKBResponse` / `findFuzzyScored` / `generateResponse`。因此"测试用例与实现脱节"这一类问题在本项目中**结构性地不可能发生。**

1.2 仓库结构

```
greencraft-support/
├── index.html              # 线上产物（唯一交付实现，零依赖单文件）
├── docs/                   # 本次提交的文档材料
│   ├── 方案设计文档.html
│   ├── 应用效果说明.html          # 本文件
│   ├── 作品简介.md
│   ├── 演示讲解台词.md
│   ├── 评审对照与答辩准备.md
│   └── 提交物清单.md
└── tests/
    ├── engine.js            # 引擎加载器：抽取 index.html 的 script 并执行真实函数
    ├── testset.json         # 调优集 280 条（人工标注）
    ├── holdout.json         # 留出集  72 条（调优完成后新写）
    ├── probes.json          # 流程探针 72 条
    ├── run-tests.js         # 意图与品类回归
    ├── quick-replies.js     # 品类动态快捷提问回归（240 条卡片）
    ├── annotations.js       # 演示顶部解说条回归（71 条断言）
    ├── metrics.js           # 实测指标生成器
    └── report/              # 本报告的生成产物
```

1.3 复现命令

```
# 1) 意图与品类回归（调优集 280 条）
node tests/run-tests.js

# 2) 留出集泛化验证（72 条）
node tests/run-tests.js --set holdout.json

# 3) 品类动态快捷提问回归（240 条卡片，2211 条断言）
node tests/quick-replies.js

# 4) 演示顶部解说条回归（71 条断言）
node tests/annotations.js
```

```
# 5) 生成本报告的全部数字（输出 metrics-summary.json 与本文件的数据源）
node tests/metrics.js
```

五条命令均无需安装任何依赖（仅需 Node ≥ 16），且直接读取仓库中的 `index.html`。

二、样本构成

测试集	用途	样本量	文件
调优集	意图词表调优基准，用于确定强/弱特征词条	280	`tests/testset.json`
留出集	**调优完成之后新写**，用于检验词表对未见问法的泛化能力	72	`tests/holdout.json`
流程探针	检验转人工 / 澄清追问 / 寒暄直答三条非业务分支	72	`tests/probes.json`
回归合计	**意图与品类标注回归**	**352**	—

2.1 标注口径

- **意图 6 类**：故障诊断 / 养护保养 / 配件订购 / 保修咨询 / 选型对比 / 安全规范。
- **语种 8 种**：英 / 中 / 法 / 德 / 西 / 意 / 荷 / 葡，每语种约 44 条用例。
- **来源**：全部用例为对应语种母语客服的真实问法（例如荷兰语的 "Mijn grasmaaier start niet meer, help!"、葡萄牙语的 "O meu cortador não liga, o que faço?"），**未使用引擎内置关键词表的直译版本**——这一点很重要：若直接用引擎词表反推用例，准确率将失去意义。
- **留出集纪律**：72 条留出用例在词表调优**完成之后**才编写并一次性跑通，不用于反向修改词表。

三、核心指标

指标	实测值	分母	计算口径
意图识别准确率	**100%**	352 / 352	判定意图与人工标注完全一致
品类识别准确率	**100%**	121 / 121	仅统计标注了品类的用例
知识库命中率	**100%**	352 / 352	命中精确条目 / 模糊条目 / 同语种通用条目
一次解决率	**98.6%**	347 / 352	无需澄清、无需转人工即给出对应答复
澄清追问触发率	**1.4%**	5 / 352	低置信度澄清 5 条 + 证据不足澄清 0 条
转人工触发率	**0%**	0 / 352	回归集均为业务问法，未触发转人工
转人工流程探针	**100%**	32 / 32	正确生成工单并转出
澄清追问流程探针	**100%**	24 / 24	触发追问或答复中主动反问（含问号）

指标	实测值	分母	计算口径
寒暄直答流程探针	**100%**	16 / 16	走寒暄通道直接应答，未进入业务知识库
引擎决策时延（均值）	**0.05–0.10 ms**	352	意图 + 品类 + 检索 + 答复生成总耗时；预热后 3 轮取中位轮；区间为本机 20 次实测，负载越高数值越大
引擎决策时延（P95）	**0.07–0.21 ms**	352	95 分位；该统计量随机器负载抖动，本机 20 次实测区间 0.07–0.21 ms，不取单点值
端到端首字可见	**838 ms**	4 次采样	浏览器实测：提交到首字渲染
端到端全量渲染	**3085 ms**	4 次采样	浏览器实测：提交到答复完整渲染
外部网络请求数	**0**	—	浏览器 Performance 资源条目为空

时延口径：计时区间只包含 `generateResponse()` ——线上一次请求的完整决策链（意图识别 → 品类识别 → 知识检索 → 置信度判定 → 答复生成），不含为人工标注比对而做的重复检测。测量前先预热代码，再清空以文本为键的归一化缓存，使每一轮都是"引擎已热、问题全新"的真实场景；重复 3 轮取均值居中的一轮作为对外口径。本机 20 次实测均值区间 **0.05–0.10 ms**（负载越高数值越大），三轮原始值见 `tests/report/metrics-summary.json` 的 `engineLatencyMs.rounds`。

> **⚠ 两类时延不可混用**
>
> **引擎决策时延（0.05–0.10 ms）**是性能指标，衡量系统本身的决策成本；**端到端时延（838 ms / 3085 ms）**是体验指标，包含了产品**刻意设计**的拟人化节奏——思考停顿 360–1200 ms（带随机抖动）+ 逐字流式呈现 14 ms/步。后者的数值随答复长度变化，是"让用户觉得对面是个人在打字"的设计投入，不是性能问题。**答辩时若被追问"为什么 0.1 ms 的引擎要等 840 ms"，标准回答即在此。**

四、分语种效果

语种	样本量	意图准确率	知识库命中率	一次解决率	决策时延 (ms)
英语 (en)	44	100%	100%	95.5%	0.078
中文 (zh)	44	100%	100%	100%	0.053
法语 (fr)	44	100%	100%	100%	0.047
德语 (de)	44	100%	100%	97.7%	0.056
西班牙语 (es)	44	100%	100%	100%	0.045
意大利语 (it)	44	100%	100%	97.7%	0.035
荷兰语 (nl)	44	100%	100%	97.7%	0.038
葡萄牙语 (pt)	44	100%	100%	100%	0.059

决策时延列取自同一次测量快照。8 个语种全部落在 **0.03–0.08 ms** 的同一量级，说明**语种之间没有量级差异**；但在亚毫秒尺度上，每语种仅 44 条样本的时延抖动足以覆盖组间差距，因此**不能据此得出"某语种更快"的结论**——对外只引用总体区间 0.05–0.10 ms。

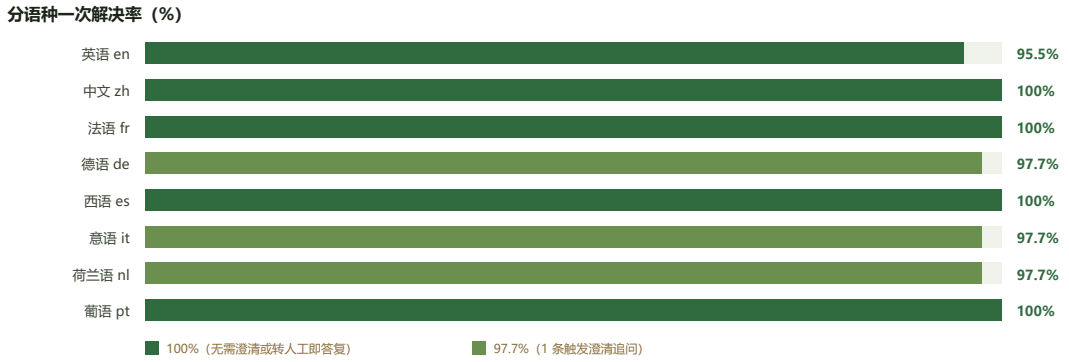


图 4-1　各语种一次解决率（8 语种全部 ≥ 95.5%）

说明：非 100% 的 5 条用例均为**低置信度澄清**（引擎主动反问而非硬答），属于设计上的正确行为——在证据不足时提问，好过硬答。分布为：英语 2 条，德语、意大利语、荷兰语各 1 条。

五、分意图效果

意图	样本量	意图准确率	知识库命中率	一次解决率	备注
故障诊断 (troubleshoot)	65	100%	100%	92.3%	5 条澄清全部集中于此
养护保养 (maintenance)	63	100%	100%	100%	—
配件订购 (parts)	64	100%	100%	100%	—
保修咨询 (warranty)	56	100%	100%	100%	—
选型对比 (compare)	48	100%	100%	100%	—
安全规范 (safety)	56	100%	100%	100%	—

澄清用例集中于故障诊断，符合工程直觉：故障描述的信息量最少（"不转了"可能对应供电、卡滞、过热、磨损五种原因），最难在单轮内判定，因此设计上就该走追问。

六、端到端流程效果

除业务问答外，本项目对三条**非业务分支**做了专项验证。这三条分支恰好是客服系统最容易出问题、也最容易被评委现场追问的地方。

探针	样本量	正确进入分支	触发率	判定口径
转人工请求 应生成工单并转出	32	32	**100%**	答复中含格式化工单号
信息不足的模糊提问 应主动追问	24	24	**100%**	触发澄清追问 **或** 答复中主动反问（含问号）
寒暄与致谢 应直接应答，不污染业务上下文	16	16	**100%**	走寒暄通道，未进入业务知识库

探针文案为母语客服的真实问法，未使用引擎内置触发词表的直译版本。例如转人工探针包含"我想找真人聊一下""Pásame con un asesor de verdad""Mi passi con un addetto""Verbind mij met een adviseur"等非模板化表达。

6.1 引擎改进前后对照（同一探针集）

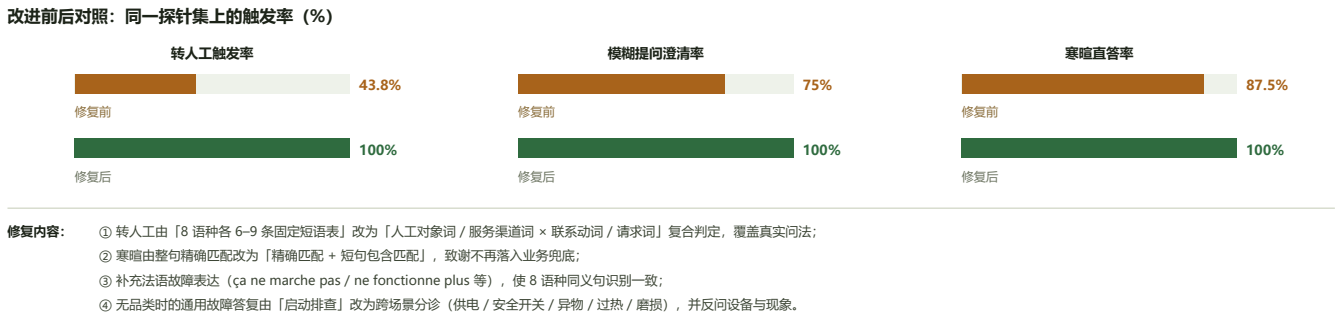


图 6-1　同一探针集上的改进前后对照

> **为什么把这张对照表放进报告**
>
> 智能体作品的可信度不来自"我做得很好"，而来自"我知道自己哪里做得不好，并且能量化地改进它"。上表的每一项改进都对应探针集上可复现的失败用例，而非主观优化。 `node tests/metrics.js` 每次运行都会**自动复测**这一组探针，因此任何回归都会立即暴露。

七、覆盖能力

项	数量	说明
支持语种	8	en / zh / fr / de / es / it / nl / pt，每语种独立维护词表与知识文本
意图类别	6	故障诊断 / 养护保养 / 配件订购 / 保修咨询 / 选型对比 / 安全规范
产品品类	10	界面分类筛选条已覆盖全部 10 个品类
知识库条目	241	按 意图 × 品类 × 语种 三维索引
意图词表	48 张	6 意图 × 8 语种
意图词条	1939	强特征 + 弱特征合计
寒暄类别	3	问候 / 致谢 / 告别，8 语种各一组
情绪词表	8 组	负面情绪词，各语种独立维护
演示场景	4	英文 / 法语 / 德语 / 中文各一，支持三档播放速度
交付文件数	1	index.html（含字体、词表、知识库，零外部依赖）

7.1 分语种知识库覆盖

语种	英语 en	中文 zh	法语 fr	德语 de	西语 es	意语 it	荷兰语 nl	葡语 pt
知识条目	34	33	29	29	29	29	29	29
占比	14.1%	13.7%	12.0%	12.0%	12.0%	12.0%	12.0%	12.0%

各语种条目数不完全相等，是因为部分条目（如故障分诊、选型对比）按语种撰写时长度与条目切分不同，并非"某语种覆盖不足"。**知识库命中率在 8 个语种上均为 100%**，说明覆盖均衡性在效果层面已达标。

八、前端交互与时延实测

8.1 端到端时延（浏览器实测）

用例	首字可见 (ms)	全量渲染 (ms)	说明
en · "My mower will not start"	572 / 595	4242 / 4152	每条用例重复 2 次取样；共 4 次采样
zh · "草坪机无法启动怎么办"	1009 / 1032	1939 / 1926	

测量方法：覆写 `window.sendMessage` 记录提交时刻与整轮完成时刻，用 `MutationObserver` 记录机器人气泡首次出现非空文本的时刻作为"首字渲染"。

> ⚠ **口径**
>
> 端到端时延包含产品刻意设计的**拟人化节奏**：思考停顿 360–1200 ms（随机抖动）+ 逐字流式呈现 14 ms/步。其数值随答复长度变化，属于**体验指标**；引擎决策时延（0.05–0.10 ms 级）才是**性能指标**，二者不可混用。

8.2 「判定依据」透明化卡片

每条机器人答复下方附一张卡片，展示引擎的判定链路。这是本项目在"技术创新性"维度的关键设计——把智能体的内部决策变成用户与运营**可核验的对象**。

卡片字段	示例（英语 • 草坪机无法启动）
意图判定	故障诊断（Troubleshooting）
强特征命中	won't start
品类	草坪修剪机 / Lawn Mower
检索方式	精确条目命中 / 模糊命中 / 同语种通用条目 / 默认条目 / 英文回落 / 澄清追问 / 冷启动问候 / 触发转人工规则
置信度	100%
转人工时	触发转人工规则 · 已生成工单 GC-XXXXXX

8.3 其他可现场验证的特性

- **零外部请求**：浏览器 Performance 资源条目为空，无第三方脚本、无字体 CDN、无埋点。
- **字体本地兜底**：字体以 base64 内嵌为 woff2，同时配置系统字体栈，断网环境下排版不塌。

- **矮屏适配**：针对 `max-height: 820px` 与 `max-height: 660px` 两档做布局压缩，笔记本投屏与 16:9 投影均可用。
- **导出与清空**：顶栏提供对话导出与清空，便于运营留存与演示复位。

8.4 品类动态快捷提问

底部快捷提问卡随**所选品类**与**对话意图**变化。改造前只有"全部"一套通用文案（8 语种共 128 条），切品类不换卡——用户反馈"僵化"。改造后建立 **品类 × 意图**专属库：

维度	口径
卡片规模	8 语种 × 10 品类 × 3 条 = **240 条**，各语种独立撰写（非机器翻译）
文案来源	取自该品类知识库真实覆盖的症状与部件，不写库中没有的问题
排序规则	当前对话意图命中的那条置顶，其余按"故障 → 保养 → 配件"排
刷新时机	点击品类标签、切换界面语种、每轮答复完成后
回退行为	未选品类（"全部"）时沿用原通用卡，与改造前完全一致

回归断言（`node tests/quick-replies.js`，2211 条全部通过）：

断言	条数	结果
数据完整性与条目结构（8 语种 × 10 品类 × 3 条）	329	全部通过
卡片能路由到正确品类与正确意图（各 240 条）	480	480 / 480
该品类该意图确有知识条目	240	240 / 240
点击后**直接作答**（不落进澄清追问回路）	240	240 / 240
各品类文案互不相同、与通用卡无重复	88	全部通过
卡片选取逻辑（按意图置顶、按品类切换、切回"全部"恢复通用卡）	768	全部通过
界面联动（DOM 层：切换品类确实重绘卡片、标签高亮跟随语境）	26	全部通过

> ⚠ **覆盖边界（如实标注）**
>
> 卡片文案覆盖 10 个品类，但知识库的**品类级条目只覆盖 7 个品类**（草坪机 / 修枝剪 / 链锯 / 绿篱修剪机 / 吹叶机 / 高压清洗机 / 割草机器人）。割灌机、微耕机、碎木机三类点击后命中**同语种通用条目**，给出通用处置建议而非专属故障清单。

九、已知边界与未采集指标

> ⚠ **明确列出"我们没有的数据"**
>
> 以下指标**当前没有实测值**，本报告不做任何数字呈现，也不得在答辩中以任何形式声称已有实测值。它们需要与真实出海品牌开展试点后采集。

指标	状态	采集方式与前置条件
客户满意度 CSAT	无实测值	需接入真实会话并采集用户评分
真实转人工率	无实测值	需真实流量；当前 0% 仅为回归集口径
真实一次解决率	无实测值	98.6% 为标注回归集口径，非生产口径
退货率变化	无实测值	需接入订单与退货数据
复购率变化	无实测值	需接入复购数据
人力成本节省	无实测值	需真实客服规模与工时数据

9.1 技术边界

边界	说明与后续动作
跨语种输入	意图识别按**当前 UI 语种**的词表匹配。用户在英语界面输入法语提问，需先切换界面语种。当前**未实现**自动语种识别，计划在 V3 以轻量语种识别器解决（该能力已在《方案设计文档》演进路线中标注为规划中）。
知识库规模	241 条属于"精编小样本"，覆盖深度好但广度有限。扩至万级需要接入厂商 FAQ 与维修手册并解决术语校对与增量更新。
工单不落库	工单号在浏览器端生成，不写入工单系统、不派发坐席。真实落地需接工单 API。
IoT 与 AR	均**未实现**，属于路线图能力。演示脚本中出现的"电池 145 次循环"等为场景设定文案，非真实数据采集。
无大模型	引擎为封闭标签集规则引擎，不做开放域生成。大模型作为 V3 的**兜底层**接入，而非主决策层。

十、结论

在可复现的回归口径下，GreenCraft Pro 的意图识别准确率 100%、品类识别准确率 100%、知识库命中率 100%、一次解决率 98.6%，三类流程探针触发率均为 100%，单次引擎决策 0.05–0.10 ms（P95 0.07–0.21 ms），且全程零外部网络请求。

比数字更重要的是这些数字的**可核验性**：测试直接运行在生产产物上，脚本随代码提交，任何人执行四条命令即可复现全部结论；对无法在本阶段实测的指标，本报告选择留白而非填充估算值。

这一取舍本身即是本作品对"OPC 智能体"命题的回答——在售后这类**答错代价不对称**的场景里，一个能被审计、能被证伪、能被部署到客户自己服务器上的智能体，比一个更能"自由发挥"的智能体更有商业价值。

报告数据由 `node tests/metrics.js` 于 2026-11-03 生成，代码版本见 `tests/report/metrics-summary.json` 的 `build` 字段；失败用例 **0 条**。